

MLSQL 开源云原生Data & AI平台

Luke Han | luke.han@kyligence.io 联合创始人 & CEO



Kyligence 公司介绍

自主开源技术,打造开源生态





- 全球领先的大数据 OLAP 领导者
- 中国首个 Apache 顶级开源项目
- 1500+ 全球生产用户



- 面向 AI 的 SQL 语言
- AI + Big Data 领域开源新秀
- 金融、互联网等行业应用案例

SQL为王,为数据分析师、数据科学家、数据工程师提供统一的全栈平台



➤ 当前落地 Data + AI 所面临的痛点

Agenda

- ➤ MLSQL是什么
- ➤ 如何使用MLSQL低成本落地 Data + Al



当前企业落地 Data + AI 所面临的痛点



6. 不同组件任务使用调度连接起来















Machine Learning with Scikit-Learn

learn



5. 持续的迭代











一线人员的五大痛点

算法落地久



Kyligence

太多组件 需要复杂的调度,运维系统 维护成本高 部署维护 数据需要在各个组件流转 数据流转 格式,形态都不一致 存在多次落盘,产生大量临时数据 算法落 • 各个地方都需要权限管控 权限管控 地均长: • 容易产生漏洞,且管理繁琐 >1周 组件太多, 资源浪费 资源难以利用均衡 使用门槛高 • 使用者需要学习各个系统, 5 • 抬高了使用门槛





企业发现落地一个算法到具体的某个场景的成本远高于其带来的收益 💸 Kyligence



招募难

企业



人才池子太小





企业愿意花钱,但依然 难以构建完整平台和招募到 足够的研发和数据科学家





MLSQL能够解决上述难题

那么 MLSQL 是什么?



MLSQL三大组成



面向大数据和AI设计的语言

成熟的底层引擎



统一语言及统一平台

语言

一个真正整合数据管理、商业分析、机器学习的



分布式 引擎



数据湖支持,CDC支持,各类算法, Python支持等大数据开箱即用功能

内置库



MLSQL 实现从桌面到云端的覆盖





像使用 SAS 软件一样,在笔记本开 箱即用,无需云端亦可工作。 一行配置使用云端 算力和存储:

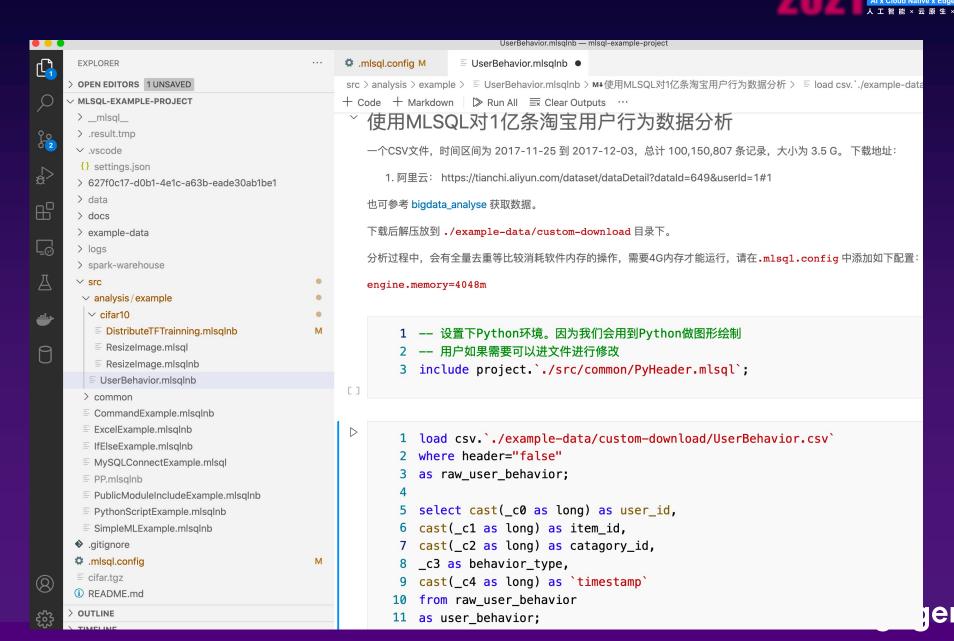
engine.url=https://m1:9003



可充分利用云原生带来的算力和存储 突破本地限制



桌面版





桌面版+云端服务

```
.mlsql.config
     engine.url=
                        .kyligence.io
     user.owner=admin
     user.access_token=123
```



TERMINAL SQL CONSOLE: MESSAGES PROBLEMS OUTPUT DEBUG CONSOLE

(dev) [w@me mlsql-example-project]\$ export MLSQL_HOME=/Users/allwefantasy/projects/mlsql/src/mlsql-lang/mlsql-app_ 2.4-2.1.0-SNAPSHOT

(dev) [w@me mlsql-example-project]\$ export PATH=\${MLSQL_HOME}/bin:\$PATH

(dev) [w@me mlsql-example-project] \$

(dev) [w@me mlsql-example-project]\$ mlsql run ./src/common/mock_data.mlsql

2021/09/06 10:00:18.825018 mlsql[25309] <INFU>: [-XMX4048M -cp /Users/attwefantasy/projects/mlsql/src/mlsql-lang/mlsql-app_2.4-2.1.0-SNAPSHOT/main/*:/Users/allwefantasy/projects/mlsql/src/mlsql-lang/mlsql-app_2.4-2.1.0-SNAPSHOT/plugin/*:/Users/allwefantasy/projects/mlsql/src/mlsql-lang/mlsql-app_2.4-2.1.0-SNAPSHOT/plugin/*:/Users/allwefantasy/projects/mlsql/src/mlsql-lang/mlsql-app_2.4-2.1.0-SNAPSHOT/spark/* streaming.core.StreamingApp -streaming.master local[*] -streaming.name MLSQL-desktop -streaming.rest false -streaming.thrift false -streaming.platform spark -streaming.spark.service false -streaming.job.cancel true -streaming.datalake.path ./data/ -streaming.driver.port 900 3 -streaming.plugin.clzznames tech.mlsql.plugins.ds.MLSQLExcelApp,tech.mlsql.plugins.shell.app.MLSQLShell -streaming.platform_hooks tech.mlsql.runtime.SparkSubmitMLSQLScriptRuntimeLifecycle -streaming.mlsql.script.path ./src/common/mock_data.mlsql -streaming.mlsql.script.owner admin -streaming.mlsql.sctipt.jobName mlsql-cli]

SLF4J: Class path contains multiple SLF4J bindings.

SLF4J: Found binding in [jar:file:/Users/allwefantasy/projects/mlsql/src/mlsql-lang/mlsql-app_2.4-2.1.0-SNAPSHOT/m ain/streamingpro-mlsql-spark_2.4_2.11-2.1.0-SNAPSHOT.jar!/org/slf4j/impl/StaticLoggerBinder.class]

SLF4J: Found binding in [jar:file:/Users/allwefantasy/projects/mlsql/src/mlsql-lang/mlsql-app_2.4-2.1.0-SNAPSHOT/s

park/slf4j-log4j12-1.7.16.jar!/org/slf4j/impl/StaticLoggerBinder.class]

SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.

SLF4J: Actual binding is of type [org.slf4j.impl.Log4jLoggerFactory]

log4j:WARN No such property [rollingPolicy] in org.apache.log4j.RollingFileAppender.

21/09/06 10:00:19 WARN NativeCodeLoader: Unable to load native—hadoop library for your platform... using builtin—java classes where applicable

21/09/06 10:00:21 INFO MLSQLStreamManager: Start streaming job monitor....

21/09/06 10:00:23 INFO SnapshotTimer: Scheduler MLSQL state every 3 seconds

21/09/06 10:00:24 INFO MLSQLExcelApp: Load ds: tech.mlsql.plugins.ds.MLSQLExcel

21/09/06 10:00:26 INFO JobManager: JobManager started with initialDelay=30 checkTimeInterval=5

21/09/06 10:00:26 INFO FileInputFormat: Total input paths to process: 1

21/09/06 10:00:26 INFO DefaultMLSQLJobProgressListener: [owner] [admin] [groupId] [6fabcb5f-0e08-45c1-9251-85d1aa

1de15c] __MMMMMM__ Total jobs: 1 current job:1 job script:load jsonStr.jsonStr as mock_data

features				label
[5.1,	3.5,	1.4,	0.2]	10
[5.1,				1000
[5.1,	3.5,	1.4,	0.2]	jø j
[4.4,	2.9,	1.4,	0.2]	[0 i
[5.1,	3.5,	1.4,	0.2]	1
[5.1,	3.5,	1.4,	0.2]	0
[5.1,	3.5,	1.4,	0.2]	[0
[4.7,	3.2,	1.3,	0.2]	1
[5.1,	3.5,	1.4,	0.2]	0
[5.1,	3.5,	1.4,	0.2]	0









私有服务

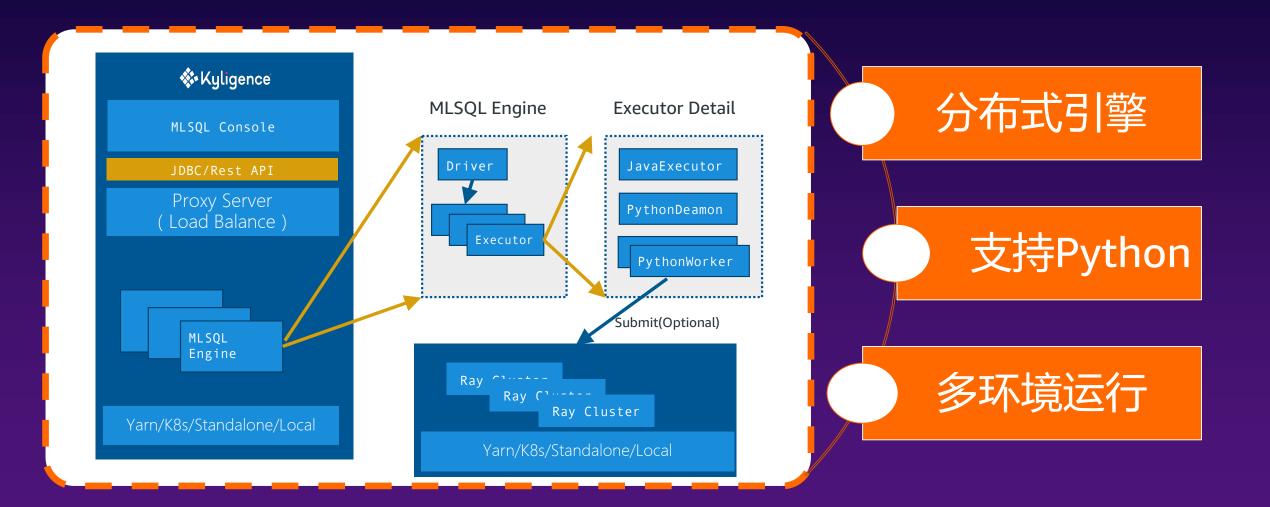
Deploying MLSQL Engine on k8s

```
## K8S config file resides in ~/.kube/config by default.
## chncaesar/mlsql-engine-k8s:3.0-2.1.0-SNAPSHOT is a pre-built K8S image
./mlsql-deploy run \
 --kube-config ~/.kube/config \
  --engine-name mlsql-k8s
 --engine-image chncaesar/mlsql-engine-k8s:3.0-2.1.0-SNAPSHOT \
  --engine-executor-core-num 2
  --engine-executor-num 1
 --engine-executor-memory 2048 \
  --engine-driver-core-num 2
  --engine-driver-memory 2048 \
 --engine-access-token mlsql
 --engine-jar-path-in-container local:///home/deploy/mlsql/mlsql-engine_3.0-2.1.0-SNAPSHOT/libs/stre
  --storage-name jfs \
  --storage-meta-url redis://127.0.0.1:6379/1
```



MLSQL 云端架构









数据科学家 大数据工程师 产品运营 应用API(譬如业务后台分析相关功能)

Apps(Notebook, Works, Scripts等)

MLSQL Engines





MLSQL如何帮助企业

低成本落地 Data + AI?



MLSQL四大特性

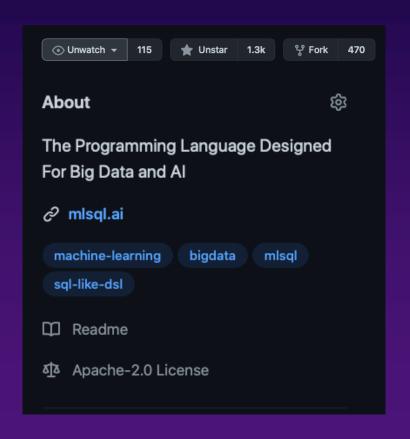






MLSQL是开源的









统一的语言

```
load excel. \text{'tmp/excel-example/triage-patient.xlsx' where useHeader="true" as triagePatient;
load excel.`/tmp/excel-example/master-email.xlsx` where useHeader="true" as masterEmail;
-- select date_format(cast (UNIX_TIMESTAMP(date, 'dd/MM/yy') as TIMESTAMP),'dd/MM/yy') as x,a
select date as x, 0 as y1, patientNum as y2 from triagePatient where triage="皮肤科"
union all
select date as x, patientNum as y1, ∅ as y2 from triagePatient where triage="眼科"
as tempTable;
select x,sum(y1) as `眼科`,sum(y2) as `皮肤科`,
-- 告诉系统需要生成图表
"line" as dash
from tempTable where x is not null group by x order by x asc
as finalTable;
select tp.*,me.email from triagePatient as tp left join masterEmail as me on tp.master==me.m
as triagePatientWithEmail;
select first(email) as x,
avg(patientNum) as patientEveryDay,master,first(email) as email,
"bar" as dash
from triagePatientWithEmail
aroup by master
order by patientEveryDay desc
as output;
save overwrite triagePatientWithEmail as excel.`/tmp/triagePatientWithEmail.xlsx`
where key="value";
```

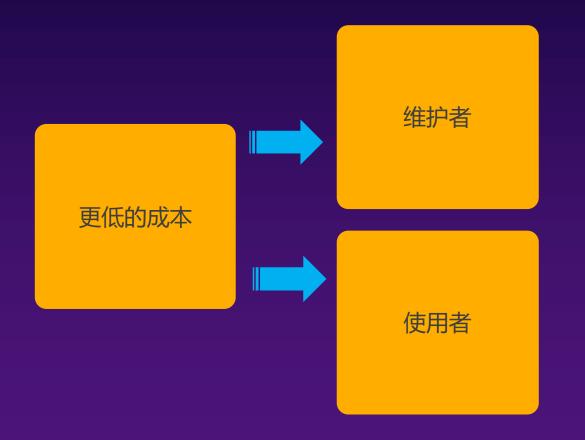
统一的引擎

Index of /2.1.0-SNAPSHOT/

../
mlsql-console-2.1.0-SNAPSHOT.tar.gz 17-Jun-2021 09:25 102M
mlsql-engine_2.4-2.1.0-SNAPSHOT.tar.gz 31-May-2021 17:42 119M
mlsql-engine_3.0-2.1.0-SNAPSHOT.tar.gz 31-May-2021 17:51 118M

















告别



几天入门

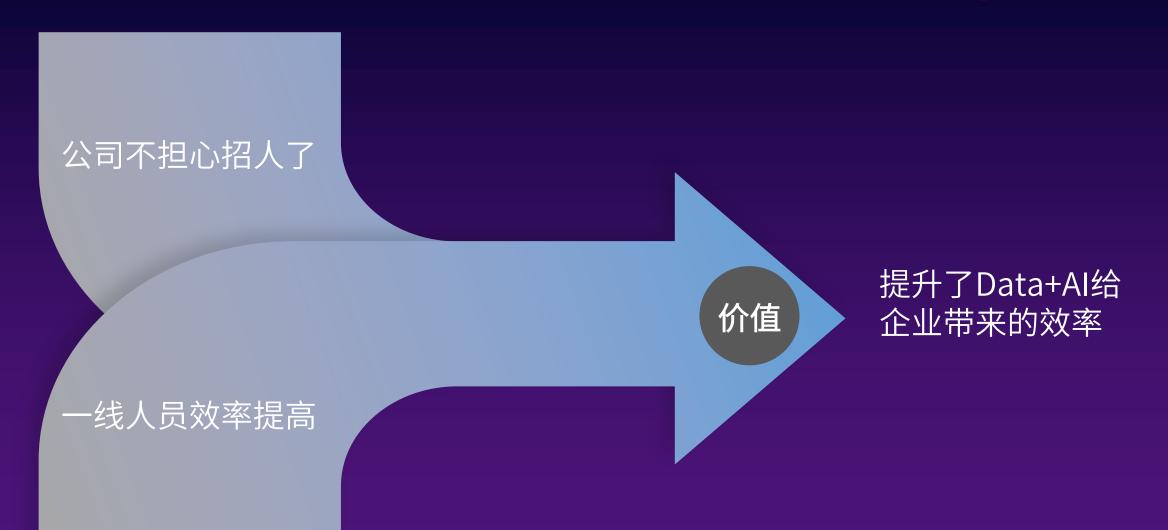
满足不同层次人 群诉求 代码易于自动化 生成

从运营产品到数据科学家,数据工程师,都可以使用功能MLSQL完成自己的工作



释放大数据+AI生产力









数据安全

- 1. 对底层数据源无侵入性
- 2. 支持表,列,行级别权限控制
- 3. 表级别权限可秒级校验,避免运行等待

语言安全

针对每个用户控制可使用语言功能

- 1. 是不是能使用某个模块、插件
- 2. 是不是能使用自定义UDF (Scala/Java)
- 3. 是不是能使用Python
- 4. Python 为沙箱,只能访问用户有权限的数据
- 5. 还有更多。。。。





- 1. 数据不搬家
- 2. 强大的权限控制
- 3. 强大的计算能力

典型场景1-某消费金融公司



易于使用

产品,运营,研发,数据科学家等等

平台能力强大

Make data analysis simple and smart

易于维护





使用情况



全公司200人

持续运行: 三年

累计任务: 700万

数据规模: TB级

支撑团队:2人



典型场景2-厦门某信息公司



客户30个模型

500+任务

Make data analysis simple and smart

4人一个月



客户一个模型2周搞不定, <u>堆人也没用</u>



开发效率15倍提升

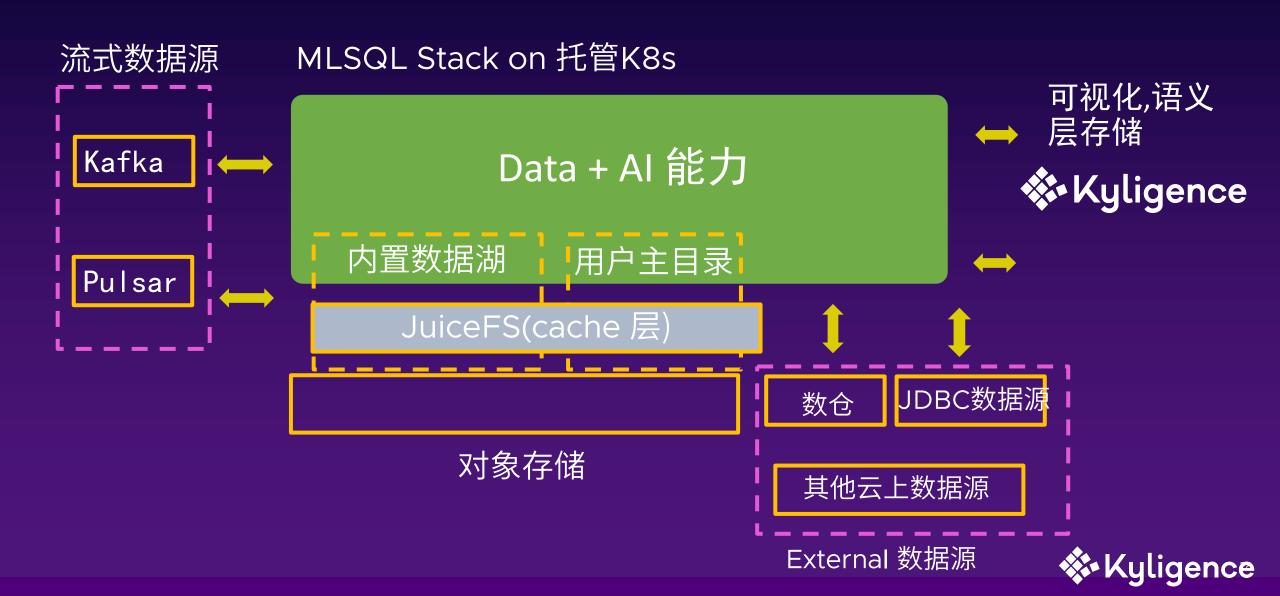
Kettle难以满足越来越复杂的数据处理,如异构join

MLSQL 脚本支持现场、远程开发部署

客户现场仅需一人维护即可







MLSQL Summary



- In Notebook
- All about SQL
- Seamless SQL & Python
- No PySpark

- Non-intrusive, out-ofbox data ACI
- Security on Plugin,
 Algorithm, Data and
 Directory
- Custom
 desensitization



- Analyze and explore multiple data sources
- Support algorithms and feature engineering, support Python ecosystem
- Support Kylin and other analytical engines
- UDF and UDAF hot deployed
- Pluggable architecture
- User defined extension





Thank You

Luke Han | luke.han@kyligence.io 联合创始人 & CEO